Programación Funcional Avanzada

Reconocedores Monádicos – Parsec

Ernesto Hernández-Novich <emhn@usb.ve>

Universidad "Simón Bolívar"

Copyright ©2010-2013



Puedes correr, pero no esconderte...

... siempre hace falta un reconocedor

- Procesar texto estructurado, procesar archivos de configuración...
- ... escribir interpretadores o escribir compiladores.
- Siempre hace falta un reconocedor.

Haskell ofrece varias alternativas



Los reconocedores "de pobre"

- Se crean estructuras de datos a tiempo de ejecución.
- Se desea conservarlas en memoria secundaria para futuras ejecuciones.



Los reconocedores "de pobre"

- Se crean estructuras de datos a tiempo de ejecución.
- Se desea conservarlas en memoria secundaria para futuras ejecuciones.
- Show a instancia que convierte de dato a String
 - El compilador la genera automáticamente.
 - "Imprimir" un dato en un archivo es simple print.
 - El programador puede refinarla de ser necesario.



Los reconocedores "de pobre"

- Se crean estructuras de datos a tiempo de ejecución.
- Se desea conservarlas en memoria secundaria para futuras ejecuciones.
- Show a instancia que convierte de dato a String
 - El compilador la genera automáticamente.
 - "Imprimir" un dato en un archivo es simple print.
 - El programador puede refinarla de ser necesario.
- Read a instancia que convierte de String a dato.
 - El compilador la genera automáticamente.
 - "Leer" un dato es simple read
 - Refinarla no es nada sencillo.



Los reconocedores "de pobre"

- Se crean estructuras de datos a tiempo de ejecución.
- Se desea conservarlas en memoria secundaria para futuras ejecuciones.
- Show a instancia que convierte de dato a String
 - El compilador la genera automáticamente.
 - "Imprimir" un dato en un archivo es simple print.
 - El programador puede refinarla de ser necesario.
- Read a instancia que convierte de String a dato.
 - El compilador la genera automáticamente.
 - "Leer" un dato es simple read
 - Refinarla no es nada sencillo.

Para muchos problemas simples, es una solución rápida.



Parsec - Parser Combinators

- Librería de combinadores monádicos para construir reconocedores
 - Gramáticas sensibles al contexto.
 - Lookahead infinito backtracking.
 - Máxima eficiencia en gramáticas predictivas LL(k).



Parsec - Parser Combinators

- Librería de combinadores monádicos para construir reconocedores
 - Gramáticas sensibles al contexto.
 - Lookahead infinito backtracking.
 - Máxima eficiencia en gramáticas predictivas LL(k).
- Ventajas sobre otros similares ("a mano", Parse::RecDescent, ANTLR, . . .)
 - Un sólo lenguaje para expresar el reconocedor Haskell.
 - Reconocedores son objetos de primera clase reconocedores complejos a partir de reconocedores simples.
 - Aprovechar funciones monádicas
 - Son Monad todo lo de Control.Monad.
 - Son Functor todo lo de Data.Functor.
 - Son Applicative todo lo de Control. Applicative
- Debería ser la primera alternativa, a menos que se necesite LR.



Parsec - Parser Combinators

- Librería de combinadores monádicos para construir reconocedores
 - Gramáticas sensibles al contexto.
 - Lookahead infinito backtracking.
 - Máxima eficiencia en gramáticas predictivas LL(k).
- Ventajas sobre otros similares ("a mano", Parse::RecDescent, ANTLR, . . .)
 - Un sólo lenguaje para expresar el reconocedor Haskell.
 - Reconocedores son objetos de primera clase reconocedores complejos a partir de reconocedores simples.
 - Aprovechar funciones monádicas
 - Son Monad todo lo de Control.Monad.
 - Son Functor todo lo de Data.Functor.
 - Son Applicative todo lo de Control. Applicative
- Debería ser la primera alternativa, a menos que se necesite LR.

Parser monádico aplicativo



Parsec – Robustez para aplicación práctica

Diseñado para ser aplicable en el "mundo real"

- Velocidad miles de líneas por segundo.
- Reporte de errores alto nivel, localizables y contextuales.
- Componentes básicos y complejos "listos para usar"
 - Analizador lexicográfico.
 - Reconocedor general de expresiones.
 - Reconocedor para permutaciones.
- Documentación usuario y referencia.
- Predictivo por omisión, backtracking debe indicarse explícitamente.



Reconocer un archivo CSV light

- Un archivo CSV (Comma Separated Values)...
 - Varias líneas, seguidas por el fin de archivo.
 - Cada línea tiene uno o más campos, seguidos por el fin de línea.
 - Campos separados por comas no contienen comas ni saltos de línea.



Reconocer un archivo CSV light

- Un archivo CSV (Comma Separated Values)...
 - Varias líneas, seguidas por el fin de archivo.
 - Cada línea tiene uno o más campos, seguidos por el fin de línea.
 - Campos separados por comas no contienen comas ni saltos de línea.
- Nuestro reconocedor
 - Debe recibir un String como entrada.
 - ¿Estructura correcta? lista de listas de campos [[String]].
 - ¿Estructura incorrecta? indicar el error.



Reconocer un archivo CSV - Primer intento

```
import Text.ParserCombinators.Parsec
csv :: GenParser Char st [[String]]
csv = do r \leftarrow many line
         eof
         return r
line :: GenParser Char st [String]
line = do r <- cells
          eol
          return r
cells :: GenParser Char st [String]
cells = do f <- content
           n <- moreCells
           return (f:n)
```



Reconocer un archivo CSV – Primer intento

```
moreCells :: GenParser Char st [String]
moreCells = (char ',' >> cells) <|> (return [])
content :: GenParser Char st String
content = many $ noneOf ",\n"
eol :: GenParser Char st Char
eol = char '\n'
parseCSV :: String -> Either ParseError [[String]]
parseCSV = parse csv "csv"
```

Eso es todo – en serio.



Combinadores de Parsec

Un API simple, pero constructivo

- many p aplicar el parser p tantas veces como pueda.
- eof reconoce el fin de archivo.
- char c reconoce un caracter específico.
- noneOf s reconoce un caracter que **no** esté en el conjunto indicado.
- p <|> q (choice)
 - Intenta aplicar el parser p
 - Si el parser p falla pero no consumió nada de la entrada, entonces aplica el parser q.
- parse p n aplica el parser p sobre la entrada, usando n para identificar los mensajes de error.

¿Cómo funcionan?



Corto-circuito de resultados

• ¿Cuál es la mecánica de un reconocedor (parser)?



- ¿Cuál es la mecánica de un reconocedor (parser)?
 - Procesa texto (String) de entrada.



- ¿Cuál es la mecánica de un reconocedor (parser)?
 - Procesa texto (String) de entrada.
 - Consume la parte que cumple con determinado criterio, retornando retorna el resto junto con alguna representación de lo consumido – corresponde a un éxito inmediato.



- ¿Cuál es la mecánica de un reconocedor (parser)?
 - Procesa texto (String) de entrada.
 - Consume la parte que cumple con determinado criterio, retornando retorna el resto junto con alguna representación de lo consumido – corresponde a un éxito inmediato.
 - Si no consume nada de la entrada, intenta el siguiente reconocedor secuencia de alternativas en algún orden práctico.



- ¿Cuál es la mecánica de un reconocedor (parser)?
 - Procesa texto (String) de entrada.
 - Consume la parte que cumple con determinado criterio, retornando retorna el resto junto con alguna representación de lo consumido – corresponde a un éxito inmediato.
 - Si no consume nada de la entrada, intenta el siguiente reconocedor secuencia de alternativas en algún orden práctico.
 - Si ninguno tiene éxito, reporta la falla de forma razonable fracaso con diagnóstico.



Corto-circuito de resultados

- ¿Cuál es la mecánica de un reconocedor (parser)?
 - Procesa texto (String) de entrada.
 - Consume la parte que cumple con determinado criterio, retornando retorna el resto junto con alguna representación de lo consumido – corresponde a un éxito inmediato.
 - Si no consume nada de la entrada, intenta el siguiente reconocedor secuencia de alternativas en algún orden práctico.
 - Si ninguno tiene éxito, reporta la falla de forma razonable fracaso con diagnóstico.
- ¡Esto es exactamente lo que ofrece MonadPlus!
 - Parsec es Functor y Applicative.
 - Parsec es Monad y MonadPlus.
 - Parsec es MonadTransformer.

Reconocedor recursivo descendente con *backtracking*.



Construyamos un reconocedor

...aprovechar Parsec será más fácil después

 Procesa un String como entrada – retorna los posibles resultados con el resto de la entrada

```
newtype Parser a = Parser (String -> [(a,String)]
```

- Fracaso lista vacía.
- Múltiples resultados tuplas con lo reconocido y entrada por procesar.
- Modelamos la ambigüedad posibilidad de backtrack.

Obviaremos errores y AST por ahora.



Parser y sus instancias

Parser es Monad - híbrido List y State.

```
instance Monad Parser where
 return a = Parser (\cs -> [(a,cs)])
 p >>= f = Parser (\cs -> concat [
      parse (f a) cs' | (a,cs') <- parse p cs
parse (Parser p) = p
```



Parser y sus instancias

Parser es Monad - híbrido List y State.

```
instance Monad Parser where
 return a = Parser (\cs -> [(a,cs)])
 p >>= f = Parser (\cs -> concat [
      parse (f a) cs' | (a,cs') <- parse p cs
parse (Parser p) = p
```

Parser es MonadPlus.

```
instance MonadPlus Parser where
 mzero = Parser (\cs -> [])
 p 'mplus' q = Parser (\cs -> parse p cs ++
                              parse q cs)
```



Un ejemplo trivial

item – reconocer un caracter cualquiera

... ya nos permite escribir cosas como

```
p :: Parser (Char, Char)
p = do
    c <- item
    item
    d <- item
    return (c,d)</pre>
```



Reconocer caracteres que cumplan algún predicado

```
satisfy :: (Char -> Bool) -> Parser Char
satisfy p = do
 c <- item
 if p c then return c else return mzero
```



Reconocer caracteres que cumplan algún predicado

```
satisfy :: (Char -> Bool) -> Parser Char
satisfy p = do
 c <- item
  if p c then return c else return mzero
```

• Reconocer el caracter c en particular

```
char :: Char -> Parser Char
char c = satisfy (c==)
```



Reconocer caracteres que cumplan algún predicado

```
satisfy :: (Char -> Bool) -> Parser Char
satisfy p = do
 c <- item
  if p c then return c else return mzero
```

Reconocer el caracter c en particular

```
char :: Char -> Parser Char
char c = satisfy (c==)
```

Reconocer cualquier dígito

```
digit :: Parser Char
digit = satisfy isDigit
```



Controlando el no-determinismo

... porque a veces quiero uno o el otro, excluyente

- mplus equivale al no-determinismo
 - Se intentan ambos reconocedores.
 - Se combinan sus resultados.
 - En ocasiones sólo interesa si el primero de una secuencia tiene éxito.
- Definimos un combinador de alternativa determinística

• p +++ q – expresión regular p + q



Una afortunada cadena de eventos...

Reconocer una cadena particular



Una afortunada cadena de eventos...

Reconocer una cadena particular

• Aplicar el reconocedor p cero o más veces



Una afortunada cadena de eventos...

Reconocer una cadena particular

• Aplicar el reconocedor p cero o más veces

- many p expresión regular p*
- many1 p expresión regular pp*



Separadores

 Aplicar el reconocedor p, intercalando aplicaciones del reconocedor sep cuyo resultado no es importante pues actúa como separador



Separadores

 Aplicar el reconocedor p, intercalando aplicaciones del reconocedor sep cuyo resultado no es importante pues actúa como separador

- $sepBy1 expresión regular p(sep p)^*$
- sepBy expresión regular $p(sep p)^* + \lambda$



De regreso en Parsec

- Parsec está construido con el mismo principio
 - Parametriza el producto del reconocedor AST.
 - Parametriza el tipo de la entrada token genérico.
 - Permite que el usuario incluya estado adicional.

```
GenParser tok st a
```

• En la práctica tokens son caracteres y no se incorpora estado.

```
type Parser a = GenParser Char () a
```

• Se aplica a una entrada y se ofrece el resultado en el Monad Error

```
parse :: Parser a
    -> FilePath -> String
    -> Either ParseError a
```



De regreso en Parsec

Más combinadores

many, many1, sepBy y sepBy1 – idénticos a los ya descritos.

```
id = do c <- letter
        cs <- many (letter <|> digit <|> char '_')
        return (c:cs)
word = many1 letter
lista p = p 'sepBy' (char ',')
```

 endBy y endBy1 – aplica un reconocedor cero o más veces, separado y terminado con otro.

```
instrucciones = instruccion 'endBy' (char ';')
```



Más combinadores

 between – aplicar un reconocedor encerrado entre dos reconocedores, posiblemente diferentes

• string - reconoce una cadena específica.



Lookahead infinito

- Si nuestra gramática no es LL(1) habrá ambigüedades.
- Los combinadores siempre consumen entrada hasta fallar.
- Consideremos p <|> q
 - Si p y q tienen prefijos similares, una falla en p ocasionará la falla en q.
 - Una solución es factorizar por izquierda a veces no se puede.

```
bad = string "for" <|> string "foreach" <|> ident
```



Lookahead infinito

- Si nuestra gramática no es LL(1) habrá ambigüedades.
- Los combinadores siempre consumen entrada hasta fallar.
- Consideremos p <|> q
 - Si p y q tienen prefijos similares, una falla en p ocasionará la falla en q.
 - Una solución es factorizar por izquierda a veces no se puede.

```
bad = string "for" <|> string "foreach" <|> ident
```

- try p Intenta reconocer p.
 - Si tiene éxito, entrega el resultado.
 - Si fracasa, se "devuelve" la entrada consumida.

```
good = try (string "for")
      <!> try (string "foreach")
      <!> try ident
```



Manejo de errores

- Un reconocedor falla retornando un error (ParseError)
 - errorPos extrae la posición del error.
 - errorMessages extrae los mensajes de error.
- A partir de la posición (SourcePos)
 - sourceName, sourceLine y sourceCol obtienen los detalles.
 - Más funciones para control fino de las posiciones.
- <?> modificación de errores
 - p <?> msg se comporta como p en caso de éxito.
 - Pero en caso de fallar **sin** consumir entrada, el mensaje de error estándar de p será *reemplazado* con msg.



Reconocer archivos CSV – Reloaded

Con todos los jugueticos

El nivel más alto de abstracción

```
import Text.ParserCombinators.Parsec
csvFile = endBy line eol
line = sepBy cell (char ',')
cell = quotedCell <|> many (noneOf ",\n\r")
```



Reconocer archivos CSV – Reloaded

Con todos los jugueticos

El nivel más alto de abstracción

```
import Text.ParserCombinators.Parsec
csvFile = endBy line eol
line = sepBy cell (char ',')
cell = quotedCell <|> many (noneOf ",\n\r")
```

Ahora es trivial incluir celdas entre comillas

```
quotedCell = do
  char '"'
  content <- many quotedChar
  char '"' <?> "quote at end of cell"
  return content
```



Reconocer archivos CSV - Reloaded

Con todos los jugueticos

Un caracter "escapado"

```
quotedChar =
  noneOf "\"" <|> try (string "\"\"" >> return '"')
```



Reconocer archivos CSV - Reloaded

Con todos los jugueticos

Un caracter "escapado"

```
quotedChar =
  noneOf "\"" <|> try (string "\"\"" >> return '"')
```

El fin de línea en cualquier sistema operativo



Reconocer archivos CSV - Reloaded

Con todos los jugueticos

El programa principal



Un ejemplo más ...

Algunas aplicaciones web (mal hechas) reciben parámetros a través del URL vía la operación HTTP GET.

- La codificación se llama application/x-www-form-urlencoded.
- Cada pareja clave-valor está separada por un ampersand.
- En un valor, los espacios en blanco se codifican con un símbolo +.
- Cualquier otro símbolo está en hexadecimal, precedido por un %.



Usando Parsec

Las parejas están separadas por ampersand

```
p_query = p_pair 'sepBy' char '&'
```



Usando Parsec

Las parejas están separadas por ampersand

```
p_query = p_pair 'sepBy' char '&'
```

En la pareja, es posible que haya clave sin valor

```
p_pair = do
  name <- many1 p_char
  value <- optionMaybe (char '=' >> many p_char)
  return (name, value)
```

- optionMaybe envuelve el resultado de un reconocedor en Maybe.
- Las tuplas resultantes serán (String, Maybe String).



Usando Parsec

Resta reconocer caracters y dígitos hexadecimales

```
p_char = oneOf urlBaseChars
         <|> (char '+' >> return " ")
         <|> p hex
urlBaseChars = ['a'...'z'] ++ ['A'...'Z'] ++
               ['0'..'9'] ++
               "$- .|*'(),"
p_hex = do char '%'
           a <- hexDigit
           b <- hexDigit
           let ((d, ): ) = readHex [a,b]
           return . toEnum $ d
```

- hexDigit combinador que reconoce dígitos hexadecimales.
- readHex está en el módulo Numeric.



Aumentando la abstracción

Abreviar aprovechando combinadores monádicos – en lugar de . . .

```
p_pair = do
  name <- many1 p_char
  value <- optionMaybe (char '=' >> many p_char)
  return (name, value)
```



Aumentando la abstracción

Abreviar aprovechando combinadores monádicos – en lugar de . . .

```
p_pair = do
  name <- many1 p_char
  value <- optionMaybe (char '=' >> many p_char)
  return (name, value)
```

... puede escribirse

¡Aplicar reconocedores y combinar resultados!



Reconocedor evaluador - Expresiones

$$E \rightarrow T + E$$

 $E \rightarrow T - E$
 $E \rightarrow T$



Reconocedor evaluador - Términos

$$T \rightarrow P * T$$
 $T \rightarrow P / T$
 $T \rightarrow P$



Reconocedor evaluador - Potencias

$$P \rightarrow F \wedge P$$

 $P \rightarrow F$



Sólo el reconocedor - Factores

$$F \rightarrow (E)$$

 $F \rightarrow \text{num}$



Mientras tanto, en Text.Parsec

- Funciones de acceso para línea, columna y archivo en proceso para refinar el reporte de errores.
- Text.Parsec.Language lenguajes listos para usar
 - ¿Necesitas un analizador lexicográfico de Haskell?

```
haskell :: TokenParser st
```

• ¿Necesitas un reconocedor de Haskell?

```
haskellDef :: LanguageDef st
```

- Text.Parsec.Token generador de lexicográficos.
- Text.Parsec.Bytestring para el mundo real.



¿Tienes que implantar un lenguaje completo?

Primero un lexer - Text.Parsec.Token

• Definir patrones para comentarios, identificadores, palabras reservadas, operadores reservados...

```
guayoyoDef = emptyDef {
   commentStart = "/*",
   commentEnd = "*/",
   identStart = letter <|> char '_'
   identLetter = alphaNum <|> char '_'
   opStart = oneOf "*+-/<=>"
   reservedNames = [ "if", "while", "for", ... ]
}
```



¿Tienes que implantar un lenguaje completo?

Primero un lexer - Text.Parsec.Token

• Definir patrones para comentarios, identificadores, palabras reservadas, operadores reservados...

```
guayoyoDef = emptyDef {
   commentStart = "/*",
   commentEnd = "*/",
   identStart = letter <|> char '_'
   identLetter = alphaNum <|> char '_'
   opStart = oneOf "*+-/<=>"
   reservedNames = [ "if", "while", "for", ... ]
}
```

• ...y luego makeTokenParser genera el reconocedor Parsec.

guayoyoTokenParser = makeTokenParser guayoyoDef



¿Tienes que implantar un lenguaje completo?

Seguro hay expresiones - Text.Parsec.Expr

• Definir nombres de operadores, asociatividades y precedencias

```
table = [
  [ prefix "-" negate, prefix "+" id ],
  [ postfix "++" (+1), postfix "--" (-1) ],
  [ binary "*" (*) AssocLeft,
   binary "/" (div) AssocLeft ],
  [ binary "+" (+) AssocLeft,
   binary "-" (-) AssocLeft ]
binary n f = Infix (reservedOp n >> return f)
prefix n f = Prefix (eservedOp n >> return f)
postfix n f = Postfix (reservedOp n >> return f)
```

• ... buildExpressionParser *genera* el reconocedor Parsec.

```
expr = buildExpressionParser table
```

Escribir un compilador o interpretador complejo

Cuando LR es inevitable

 Cuando el lenguaje requiere un análisis de contexto más complejo – transformarlo a LL puede ser imposible o impráctico.



Escribir un compilador o interpretador complejo

Cuando LR es inevitable

- Cuando el lenguaje requiere un análisis de contexto más complejo transformarlo a LL puede ser imposible o impráctico.
- Alex generador de analizadores lexicográficos.
 - Lista de expresiones regulares asociadas con acciones Haskell.
 - Funcional puro o monádico depende del reconocedor en uso.



Escribir un compilador o interpretador complejo

Cuando LR es inevitable

- Cuando el lenguaje requiere un análisis de contexto más complejo transformarlo a LL puede ser imposible o impráctico.
- Alex generador de analizadores lexicográficos.
 - Lista de expresiones regulares asociadas con acciones Haskell.
 - Funcional puro o monádico depende del reconocedor en uso.
- Happy generador de reconocedores LR.
 - Reglas gramaticales con acciones Haskell asociadas las acciones se ejecutan al reducir (DFS de izquierda a derecha).
 - Reconocedor puro o monádico intención es hilvanar un Monad a la medida para gestión de estado, manejo de errores y I/O.
 - LALR(1) por omisión GLR eficiente para gramáticas ambiguas.
 - Soporte explícito para gramáticas de atributos.

Eso es lo que usarías en Traductores o en la cadena de Lenguajes de Programación.

Quiero saber más...

- Página del proyecto Parsec
- Sección de Parsec en Haskell WiKi
- Un reconocedor para Scheme usando Parsec
- Alex User Guide
- Happy User Guide

